Administracja

Agenda

- 1. Topologia klastrów obliczeniowych w Big Data
- 2. Metody instalacji narzędzi
- 3. Zarządzanie i Monitoring

Topologia klastrów

- "Active-Standby"
- "Gold-silver"
- Active Active ?

Gdzie można uruchamiać?

- Własna serwerownia
- Google Cloud
- Amazon AWS
- Microsoft Azure

Zarządzanie infrastrukturą

- Terraform
- AWS CloudFormation

Terraform

```
provider "aws" {
    region = "eu-west-1"
module "ec2" {
    instance_count = 2
                    = "example-normal"
    name
    ami
                   = "<id_obrazu_do_uruchomienia>"
    instance_type = "m4.large"
    subnet_id
                     = "<subnet_id>"
    vpc_security_group_ids = ["<security_group_id>"]
    associate_public_ip_address = true
```

Zarządzanie konfiguracją


- Puppet
- Chef
- Ansible

Puppet

```
package { 'mysql-server':
 ensure => installed,
service { 'hadoop-yarn-resourcemanager':
 ensure => running,
user { 'janusz':
 ensure => present,
 uid => '1521',
 gid => '1345',
 shell => '/bin/bash',
home => '/home/janusz'
```

Zarządzanie klastrami Hadoop

- Apache Ambari
- Cloudera Manager



Home

30 minutes preceding November 3, 2015, 1:44 PM PST

Cluster 1 (CDH 5.5.0, Packages)		Charts	30m 1h 2h 6h 12h 1d 7d 30d 2	
⊞ Hosts	* 4		Cluster CPU	Cluster Disk IO
₱ FLUME-1		•	100%	977K/s
₩ HBASE-1		•	50%	488K/s
B HDFS-1	*1		90	4007/5
W HIVE-1			0% 01:15 01:30	01:30 Cluster 1, Total Disk 0 = Cluster 1, Tot 297K/s
(I) HUE-1	*1	•	■Cluster 1 2.4% ■Cluster 2 1.6%	= Cluster 2, Total 68.3b/s = Cluster 2, Total 99K/s
¥ IMPALA-1		•	Cluster Network IO	HDFS IO
% KAFKA-1		•		
★ KS_INDEXER-1			39.1K/s	20b/s
 € KUDU-1			19.5fVs	bytes / s
₩ MAPREDUCE-1		•	S 01 01:15 01:30	ති 01:15 01:30
OOZIE-1			 Cluster 1, Tot 25.3K/s Cluster 1, Tot 23.6K/s Cluster 2, Tot 19.2K/s Cluster 2, Tot 23.3K/s 	
SSOLR-1			= 0.03101 2, 10t 13.2N/S	2., 10ta 5 1D/S _ 1101 0 - 2., 10ta 2.00/S
SPARK_ON_YA			Running MapReduce Jobs	Completed Impala Queries
SQOOP-1		•		puo
SQOOP_CLIENT-1			sgol	Does /
₩ YARN-1			<u> </u>	duerlies

Zabezpieczenie danych

- Non secure mode
- Kerberos
- HiveServer

Monitorowanie

- Działanie procesów (czy np. odpowiada na porcie?)
- Statystyki systemu operacyjnego
- Utylizacja zasobów OS
- Monitoring JMX (procesy Javy)
- Testy funkcjonalne

Jakie parametry monitorować?

- Ilość bloków
- llość plików
- Utylizacja pamięci / YARN
- Ilość aplikacji w różnych stanach
- Ilość błędnych aplikacji oraz kontenerów
- Użycie pamięci + GC dla procesów HDFS+YARN

Narzędzia do metryk

- "Time Series DB"
- Graphite
- InfluxDB
- OpenTSDB
- Grafana

